



Πανεπιστήμιο Μακεδονίας
Τμήμα Εφαρμοσμένης Πληροφορικής
7ο εξάμηνο | Ακαδημαϊκό Έτος: 2025 – 2026

Μηχανική Μάθηση 1η Εργασία – Classification problems

Τελική Αναφορά:

*Συγκριτική Αξιολόγηση Αλγορίθμων Μηχανικής Μάθησης για την
Πρόβλεψη Εταιρικής Πτώχευσης*

	Ον/μο	Αρ. Ακαδημαϊκού Μητρώου
Μέλος 1	Παρασκευούδης Στέφανος	ics23130
Μέλος 2	Παναγιωτίδης Θεόδωρος	ics22071
Μέλος 3	Παπαγιάννης Νικόλαος	ics23173
Μέλος 4	Μπλιώνα Αλίκη	ics23099

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

1. Περίληψη (Executive Summary)	2
2. Μεθοδολογία (Methodology)	2
3. Οργάνωση Ομάδας και Ανάλυση Τεχνικής Υλοποίησης	3
3.1. Μέλος 1: Προετοιμασία Δεδομένων (Data Engineering)	3
3.2. Μέλος 2: Αρχιτεκτονική Πειράματος & Εξισορρόπηση (Pipeline & Balancing)	3
3.3. Μέλος 3: Εκπαίδευση, Αξιολόγηση & Καταγραφή (Model Training & Evaluation)	4
3.4. Μέλος 4: Ανάλυση Αποτελεσμάτων & Συγγραφή Αναφοράς (Reporting & Business Analysis).....	4
4. Πειραματικά Αποτελέσματα	5
5. Συμπεράσματα	7
5.1. Αξιολόγηση Βάσει Στατιστικών Μετρικών	7
5.2. Έλεγχος Επιχειρηματικών Περιορισμών	8
5.3. Τελική Επιλογή Μοντέλου	9
6. Βιβλιογραφία & Αναφορές	9

1. Περίληψη (Executive Summary)

Στόχος της παρούσας εργασίας ήταν η ανάπτυξη και αξιολόγηση μοντέλων ταξινόμησης για την πρόβλεψη της πτώχευσης εταιρειών, βάσει οικονομικών δεικτών. Το σύνολο δεδομένων περιλαμβάνει στοιχεία για πάνω από 7.000 εταιρείες. Η βασική πρόκληση που κληθήκαμε να αντιμετωπίσουμε ήταν η έντονη ανισορροπία κλάσεων, καθώς οι υγιείς εταιρείες υπερτερούν συντριπτικά των χρεωκοπημένων, πρόβλημα που αντιμετωπίσαμε με την τεχνική του Undersampling. Αξιολογήθηκαν 8 διαφορετικοί αλγόριθμοι.

2. Μεθοδολογία (Methodology)

Η διαδικασία που ακολουθήθηκε είναι η εξής:

- **Προεπεξεργασία:** Αρχικά, έγινε έλεγχος για ελλειπείς τιμές και αφαίρεση των σχετικών εγγραφών (Data Cleaning). Στη συνέχεια, εφαρμόστηκε **Κανονικοποίηση (Min-Max Scaling)** σε όλους τους αριθμητικούς δείκτες, ώστε να φέρουμε τα δεδομένα στην κλίμακα $[0, 1]$ και να διευκολύνουμε τη σύγκλιση των αλγορίθμων.
- **Επικύρωση:** Χρησιμοποιήσαμε τη μέθοδο **Stratified 4-Fold Cross-Validation**. Η επιλογή αυτή διασφαλίζει ότι η αναλογία υγιών/πτωχευμένων παραμένει σταθερή σε κάθε υποσύνολο ελέγχου.
- **Αντιμετώπιση Ανισορροπίας:** Για να αποφύγουμε την πόλωση των μοντέλων υπέρ των υγιών εταιρειών, εφαρμόσαμε τεχνική **Undersampling** στο Training Set κάθε fold. Συγκεκριμένα, μειώσαμε τυχαία το πλήθος των υγιών εταιρειών ώστε η αναλογία να γίνει **3:1** (3 Υγιείς για κάθε 1 Χρεωκοπημένη). Το Test Set παρέμεινε ανέπαφο για να αντικατοπτρίζει την πραγματικότητα.
- **Μοντέλα:** Εκπαιδεύτηκαν και αξιολογήθηκαν 8 αλγόριθμοι: LDA, Logistic Regression, Decision Trees, Random Forests, k-NN, Naive Bayes, SVM και Gradient Boosting.

3. Οργάνωση Ομάδας και Ανάλυση Τεχνικής Υλοποίησης

Για την αποτελεσματική διεκπεραίωση της εργασίας, η ομάδα χωρίστηκε σε τέσσερις ρόλους. Κάθε μέλος ανέλαβε την ευθύνη για συγκεκριμένα τμήματα του κώδικα και της διαδικασίας ανάλυσης.

3.1. Μέλος 1: Προετοιμασία Δεδομένων (Data Engineering)

Το πρώτο μέλος ανέλαβε τη φόρτωση, τον καθαρισμό και την προετοιμασία των δεδομένων, ώστε να είναι κατάλληλα για επεξεργασία από αλγορίθμους μηχανικής μάθησης.

Τεχνική Υλοποίηση στον Κώδικα:

- **Φόρτωση:** Χρησιμοποίησε τη βιβλιοθήκη pandas και την εντολή `pd.read_excel()` για την εισαγωγή των δεδομένων σε δομή DataFrame.
- **Διαχείριση Κενών Τιμών:** Εντόπισε ελλειπίες εγγραφές (NaNs) και υλοποίησε στρατηγική αφαίρεσής τους μέσω της εντολής `df.dropna()`, διασφαλίζοντας την ποιότητα των δεδομένων εισόδου.
- **Κανονικοποίηση:** Το σημαντικότερο βήμα ήταν η κλιμάκωση των οικονομικών δεικτών στο διάστημα $[0, 1]$ με χρήση του MinMaxScaler.

3.2. Μέλος 2: Αρχιτεκτονική Πειράματος & Εξισορρόπηση (Pipeline & Balancing)

Το δεύτερο μέλος σχεδίασε τον πυρήνα της πειραματικής διαδικασίας, ορίζοντας τη στρατηγική ελέγχου και την αντιμετώπιση της ανισορροπίας των κλάσεων.

Τεχνική Υλοποίηση στον Κώδικα:

- **Stratified K-Fold:** Υλοποίησε τη μέθοδο Διαστρωματωμένης Διασταυρούμενης Επικύρωσης 4 πτυχών (StratifiedKFold(`n_splits=4`)). Η επιλογή του "Stratified" έγινε για να διασφαλιστεί ότι σε κάθε fold διατηρείται η αναλογία πτωχευμένων/υγιών εταιρειών.
- **Δυναμικό Undersampling:** Μέσα στον βρόχο επανάληψης, υλοποίησε έναν αλγόριθμο ελέγχου. Αν η αναλογία υγιών προς πτωχευμένων στο Training Set υπερέβαινε το 3:1, ενεργοποιούνταν η συνάρτηση `resample()`. Αυτή η συνάρτηση μείωνε τυχαία το πλήθος των υγιών εταιρειών, δημιουργώντας ένα ισορροπημένο σύνολο εκπαίδευσης.
- **Αρχικοποίηση Μοντέλων:** Δημιούργησε ένα λεξικό με τις κλάσεις των 8 αλγορίθμων, ορίζοντας σταθερό `random_state=42` για την επαναληψιμότητα των πειραμάτων.

3.3. Μέλος 3: Εκπαίδευση, Αξιολόγηση & Καταγραφή (Model Training & Evaluation)

Το τρίτο μέλος ανέλαβε την εκτέλεση της εκπαίδευσης, τον υπολογισμό και την καταγραφή των μετρικών απόδοσης.

Τεχνική Υλοποίηση στον Κώδικα:

- **Εκπαίδευση & Πρόβλεψη:** Υλοποίησε τον εσωτερικό βρόχο που εκτελεί `.fit()` στα εξισορροπημένα δεδομένα εκπαίδευσης και `.predict()` στα δεδομένα ελέγχου (Test Set).
- **Υπολογισμός Μετρικών:** Χρησιμοποίησε τη συνάρτηση `confusion_matrix` για να εξάγει τα TP, TN, FP, FN. Βάσει αυτών, υπολόγισε την Ακρίβεια, την Ανάκληση (`recall_score` με `pos_label=2`), το F1 Score και το AUC-ROC.
- **Αποθήκευση:** Συγκέντρωσε τα αποτελέσματα κάθε επανάληψης σε ένα pandas DataFrame και τα εξήγαγε σε αρχείο CSV (`balancedDataOutcomes.csv`).

3.4. Μέλος 4: Ανάλυση Αποτελεσμάτων & Συγγραφή Αναφοράς (Reporting & Business Analysis)

Το τέταρτο μέλος ανέλαβε την επεξεργασία των αποτελεσμάτων που παρήγαγε ο κώδικας, τη μετατροπή τους σε επιχειρηματικά συμπεράσματα και τη σύνταξη της τελικής αναφοράς.

Τεχνική Υλοποίηση Αυτοματοποίησης:

- **Μαζική Φόρτωση:** Υλοποίησε τη λειτουργία φόρτωσης του αρχείου `balancedDataOutcomes.csv`, χρησιμοποιώντας τη βιβλιοθήκη pandas.
- **Διανυσματικοί Υπολογισμοί:** Αντί να υπολογίζει τις μετρικές μία-μία, εφάρμοσε μαθηματικούς τύπους απευθείας σε ολόκληρες τις στήλες του DataFrame. Με αυτόν τον τρόπο υπολόγισε ταυτόχρονα για όλα τα folds και όλα τα μοντέλα:
- Τις βασικές μετρικές: **Accuracy, Precision, Recall, F1 Score.**
- Τις εξειδικευμένες μετρικές: **Specificity** και **Miss Rate.**
- **Διασφάλιση Ακεραιότητας:** Πρόσθεσε εντολή ασφαλείας `.fillna(0)` για την αντικατάσταση τυχόν τιμών NaN με το 0.
- **Εξαγωγή για Ανάλυση:** Τέλος, μετέτρεψε και εξήγαγε το επεξεργασμένο σύνολο δεδομένων σε μορφή Excel (`.xlsx`), έτοιμο για τη δημιουργία Pivot Tables.

Διαδικασία & Υλοποίηση τελικών παραδοτέων:

- **Συγκεντρωτική Ανάλυση:** Επεξεργάστηκε το CSV εξόδου στο Excel (Pivot Tables) και υπολόγισε τους μέσους όρους των μετρικών για κάθε μοντέλο στα 4 folds.
- **Έλεγχος Περιορισμών:** Εφάρμοσε τους ελέγχους για τους επιχειρηματικούς περιορισμούς (Recall $\geq 60\%$ ΚΑΙ Specificity $\geq 70\%$).
- **Τελική Σύνθεση:** Μέσω της ανάλυσης, εντοπίστηκε το βέλτιστο μοντέλο βάσει F1 Score και αξιολογήθηκε κατά πόσο τα μοντέλα ικανοποιούν τα κριτήρια της τράπεζας, οδηγώντας στη συγγραφή της τεχνικής αναφοράς.


4. Πειραματικά Αποτελέσματα

Η αξιολόγηση των μοντέλων έγινε με βάση τις μετρικές: Accuracy, Precision, Recall, F1 Score και AUC ROC. Επιπλέον, ορίσαμε δύο επιχειρηματικές μετρικές:

1. **Specificity:** Ποσοστό επιτυχούς εντοπισμού Υγιών εταιρειών.
2. **Miss Rate:** Ποσοστό χρεωκοπιών που δεν εντοπίστηκαν.

Παρακάτω παρουσιάζεται η σύγκριση των μοντέλων βάσει του μέσου **F1 Score** στο Test Set (Μέσος όρος 4 folds):

Classifier Name	Average of F1 Score
Decision Trees	0,109383865
Gradient Boosting	0,188861042
k-Nearest Neighbors	0,152395264
Linear Discriminant Analysis	0,18071598
Logistic Regression	0,180312471
Naive Bayes	0,151292918
Random Forests	0,209179232
Support Vector Machines	0,203341244
Grand Total	0,171935252



Ο αναλυτικός πίνακας επιδόσεων για τα μοντέλα είναι ο εξής:

Classifier Name	Average of ROC-AUC	Average of Accuracy	Average of Precision	Average of Recall	Average of F1 Score	Average of Specificity	Average of Miss Rate
Decision Trees	0,650235125	0,824281448	0,06198514	0,467741935	0,109383865	0,832728315	0,532258065
Gradient Boosting	0,838891491	0,901642404	0,116661268	0,5	0,188861042	0,911157814	0,5
k-Nearest Neighbors	0,800293059	0,885125047	0,091776137	0,451612903	0,152395264	0,895395491	0,548387097
Linear Discriminant Analysis	0,83625057	0,91414707	0,115966656	0,411290323	0,18071598	0,926060374	0,588709677
Logistic Regression	0,833948624	0,923105636	0,119790646	0,366935484	0,180312471	0,936282002	0,633064516
Naive Bayes	0,819372712	0,868047779	0,08882561	0,512096774	0,151292918	0,876480703	0,487903226
Random Forests	0,851794101	0,914986935	0,133731982	0,483870968	0,209179232	0,925200611	0,516129032
Support Vector Machines	0,835671232	0,927398283	0,137749921	0,399193548	0,203341244	0,939912113	0,600806452
Grand Total	0,808307114	0,894841825	0,10831092	0,449092742	0,171935252	0,905402178	0,550907258

5. Συμπεράσματα

5.1. Αξιολόγηση Βάσει Στατιστικών Μετρικών

Κατά την στατιστική αξιολόγηση, το ενδιαφέρον εστιάστηκε στο F1 Score, καθώς η Ακρίβεια (Accuracy) κρίνεται παραπλανητική σε μη ισορροπημένα δεδομένα.

Από τα πειραματικά αποτελέσματα, το **Random Forests** αναδείχθηκε με F1 περίπου 0.21. Η υπεροχή του έναντι των γραμμικών μοντέλων υποδεικνύει ότι οι σχέσεις μεταξύ των χρηματοοικονομικών δεικτών και της πιθανότητας πτώχευσης είναι **μη-γραμμικές**. Το Random Forests, μέσω της τεχνικής **Bagging (Bootstrap Aggregating)**, κατάφερε να μειώσει τη διακύμανση και να προσαρμοστεί καλύτερα στην πολυπλοκότητα των δεδομένων, αποφεύγοντας σε σημαντικό βαθμό το overfitting που συχνά παρατηρείται στα απλά Decision Trees (τα οποία είχαν τη χαμηλότερη επίδοση με F1 περίπου 0.11).

Παρότι το Random Forests ξεχώρισε, οι απόλυτες τιμές του F1 Score παρέμειναν σχετικά χαμηλές (< 0.30). Βάσει της θεωρίας και των εργαστηριακών ασκήσεων, αυτό το αποτέλεσμα είναι αναμενόμενο και αποδίδεται στους εξής τρεις παράγοντες:

1. **Απουσία Βελτιστοποίησης Υπερ-παραμέτρων (Hyperparameter Optimization):** Η χρήση των προεπιλεγμένων ρυθμίσεων (default parameters) σπάνια οδηγεί στη μέγιστη απόδοση. Στην παρούσα εργασία, επιλέχθηκε η χρήση default παραμέτρων για λόγους ισότιμης σύγκρισης. Η βιβλιογραφία υποδεικνύει ότι τεχνικές όπως το *Grid Search* ή το *Bayesian Optimization* θα μπορούσαν να αυξήσουν σημαντικά το F1 Score, προσαρμόζοντας το μοντέλο στα δεδομένα.
2. **Φύση Οικονομικών Δεδομένων & Θόρυβος:** Οι χρηματοοικονομικοί δείκτες χαρακτηρίζονται από υψηλό θόρυβο και αλληλοεπικαλύψεις μεταξύ υγιών και πτωχευμένων εταιρειών. Αυτό καθιστά τον διαχωρισμό τους δυσκολότερο, ανεξαρτήτως αλγορίθμου.
3. **Αυστηρή Αντιμετώπιση Ανισορροπίας (Undersampling):** Η επιλογή της τεχνικής Undersampling (όπως εφαρμόστηκε στον κώδικα) βοήθησε στην αύξηση της ευαισθησίας (Recall), ωστόσο οδήγησε αναπόφευκτα σε απώλεια πληροφορίας από την πλειοψηφούσα κλάση (Υγιείς). Γνωρίζουμε ότι υπάρχει πάντα ένα trade-off: για να αυξήσουμε την



ικανότητα εντοπισμού της σπάνιας κλάσης (Πτώχευση), θυσιάζουμε μέρος της συνολικής ακρίβειας.

5.2. Έλεγχος Επιχειρηματικών Περιορισμών

Η Τράπεζα έθεσε δύο αυστηρά όρια ασφαλείας:

1. **Recall $\geq 60\%$:** Να εντοπίζονται τουλάχιστον 6 στις 10 μελλοντικές πτώχευσεις.
2. **Specificity $\geq 70\%$:** Να μην απορρίπτονται άδικα πάνω από 3 στις 10 υγιείς εταιρείες.

Από την ανάλυση των αποτελεσμάτων στο Test Set προκύπτει ότι **κανένα μοντέλο δεν ικανοποιεί ταυτόχρονα και τους δύο περιορισμούς**. Συγκεκριμένα:

- Παρόλο που το **Random Forests** είχε το καλύτερο F1 Score, απέτυχε στο κριτήριο του Recall (με επίδοση περίπου 48%). Αναλυτικότερα, το μοντέλο όταν προβλέπει πτώχευση είναι συνήθως σωστό (υψηλό Precision), αλλά χάνει περισσότερες από τις μισές πραγματικές πτώχευσεις. Για την τράπεζα, αυτό είναι επικίνδυνο.
- Το **Naive Bayes** και το **Gradient Boosting** πλησίασαν περισσότερο στον στόχο του Recall (φτάνοντας κοντά στο 50-51%), θυσιάζοντας όμως ένα μέρος της ακρίβειάς τους στις υγιείς εταιρείες (χαμηλότερο Specificity). Παρόλα αυτά, ούτε αυτά κατάφεραν να αγγίξουν το όριο του 60% στο Recall.

5.3. Τελική Επιλογή Μοντέλου

Η αδυναμία όλων των αλγορίθμων να ικανοποιήσουν ταυτόχρονα τους περιορισμούς οδηγεί στα εξής συμπεράσματα:

1. **Ανεπάρκεια Δεδομένων ή Χαρακτηριστικών:** Ενδέχεται οι οικονομικοί δείκτες που δόθηκαν να μην περιέχουν επαρκή πληροφορία για να διαχωριστούν πλήρως οι δύο κλάσεις με γραμμικά ή μη-γραμμικά όρια.
2. **Ανάγκη για Threshold Tuning:** Η απόφαση των μοντέλων βασίζεται σε ένα όριο πιθανότητας 0.50 (50%). Για να αυξήσουμε το Recall πάνω από το 60% και να ικανοποιήσουμε την τράπεζα, η βέλτιστη λύση δεν είναι η αλλαγή αλγορίθμου, αλλά η **μετακίνηση του ορίου απόφασης (Threshold Moving)**. Αν, για παράδειγμα, ταξινομούμε ως "Χρεωκοπημένη" κάθε εταιρεία με πιθανότητα πτώχευσης $> 30\%$ (αντί

για $> 50\%$), το Recall θα αυξηθεί (ξεπερνώντας πιθανώς το 60%), με ελεγχόμενη μείωση του Specificity.

3. **Ανάγκη για χρήση StandardScaler:** Ενσωμάτωση του StandardScaler (αντί του MinMaxScaler) στην προ-επεξεργασία, για καλύτερη διαχείριση των ακραίων τιμών στους οικονομικούς δείκτες.

Συνεπώς, η τελική πρόταση είναι: Χρήση του μοντέλου **Gradient Boosting** (λόγω της ισορροπημένης συμπεριφοράς του κοντά στο 50% Recall και 91% Specificity) σε συνδυασμό με **μείωση του ορίου ταξινόμησης (threshold calibration)**, ώστε να επιτευχθεί ο στόχος του 60% Recall και τέλος, την ενσωμάτωση του StandardScaler.

6. Βιβλιογραφία & Αναφορές

A. Εκπαιδευτικό Υλικό & Διαλέξεις

- **Protopapadakis, E.** (2025). *L02: A tutorial on classification - A breast cancer detection scenario*. Τμήμα Εφαρμοσμένης Πληροφορικής, Πανεπιστήμιο Μακεδονίας. (Χρησιμοποιήθηκε για τη μεθοδολογία επίλυσης προβλημάτων με ανισορροπία κλάσεων).
- **Protopapadakis, E.** (2025). *L05: Performance assessment*. Τμήμα Εφαρμοσμένης Πληροφορικής, Πανεπιστήμιο Μακεδονίας. (Χρησιμοποιήθηκε για την επιλογή των μετρικών F1 Score και Recall αντί του Accuracy).
- **Protopapadakis, E.** (2025). *L08: Hyperparameter optimization*. Τμήμα Εφαρμοσμένης Πληροφορικής, Πανεπιστήμιο Μακεδονίας. (Χρησιμοποιήθηκε για την ερμηνεία της επίδρασης των default παραμέτρων στην απόδοση).

B. Τεχνική Τεκμηρίωση & Λογισμικό

- **Scikit-learn Developers.** (2024). *Scikit-learn: Machine Learning in Python*. Διαθέσιμο στο: <https://scikit-learn.org>. (Αλγόριθμοι Random Forest, Gradient Boosting και μετρικές αξιολόγησης).
- **Pandas Development Team.** (2024). *pandas: data analysis and manipulation tool*. Διαθέσιμο στο: <https://pandas.pydata.org>.
- **Imbalanced-learn Documentation.** (2024). *Undersampling techniques*. Διαθέσιμο στο: <https://imbalanced-learn.org>.

Γ. Ακαδημαϊκή Βιβλιογραφία



- **Breiman, L.** (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- **Chawla, N. V., et al.** (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. (θεωρία διαχείρισης ανισορροπίας δεδομένων).
- **Friedman, J. H.** (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 1189-1232.

Δ. Χρήση Εργαλείων Τεχνητής Νοημοσύνης: Αξιοποιήθηκαν εργαλεία Generative AI για τους εξής σκοπούς:

- **Υποστήριξη Κώδικα:** Παροχή συμβουλών για τη σύνταξη και διόρθωση σφαλμάτων (debugging) σε Python/Pandas.
- **Θεωρητική Κατανόηση:** Επεξήγηση πολύπλοκων εννοιών της θεωρίας Μηχανικής Μάθησης.
- **Γλωσσική Επιμέλεια:** Βελτίωση της ροής και της δομής του κειμένου της αναφοράς.

Διευκρινίζεται ότι το σύνολο του παραγόμενου υλικού ελέγχθηκε, επαληθεύτηκε και τροποποιήθηκε από την ομάδα εργασίας, η οποία φέρει και την αποκλειστική ευθύνη για την ορθότητα των περιεχομένων. Η αξιολόγηση των αποτελεσμάτων και τα τελικά συμπεράσματα αποτελούν πνευματική εργασία της συγγραφικής ομάδας.